

LAPORAN
ANALISIS PREDIKSI EMISI GAS KARBON MONOKSIDA PADA
PEMBANGKIT LISTRIK TENAGA GAS MENGGUNAKAN REGRESI
LINEAR



Oleh:

Jovan Gilbert Natamasindah	2310817310002
Devi Hafida Ariyani	2310817220018
Muhammad Rizky	2310817310011

PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS LAMBUNG MANGKURAT
BANJARMASIN
FEBRUARI, 2026

DAFTAR ISI

DAFTAR ISI.....	2
BAB I PENDAHULUAN	3
1.1 Latar Belakang.....	3
1.2 Sumber Dan Deskripsi Dataset.....	3
1.3 Pipeline Preprocessing.....	4
BAB II METODOLOGI.....	5
2.1 Keterbaruan dan Modifikasi Kode	5
2.2 Perancangan Stress Test.....	5
BAB III HASIL DAN PEMBAHASAN	5
3.1 Experiment Log dan Evaluasi Metrik.....	5
3.2 Perbandingan baseline regresi linier dengan model regresi Huber	7
BAB IV STRESS TEST	7
4.1 Stress Test terhadap Outlier	7
4.2 Analisis Stress Test terhadap Performa Model	7
BAB V KESIMPULAN	8
TAUTAN	8
DAFTAR PUSTAKA	9

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kebutuhan energi listrik global yang terus meningkat menuntut sistem pembangkit yang andal, menjadi Pembangkit Listrik Tenaga Gas (PLTG) sebagai pilar vital karena efisiensi termalnya yang lebih tinggi (*Global Electricity Demand Is Set to Grow Strongly to 2030, Underscoring Need for Investments in Grids and Flexibility - News - IEA*, n.d.). Namun, operasional turbin gas pada PLTG menghasilkan polutan gas buang, utamanya berupa gas Karbon Monoksida (CO) dan Nitrogen Oksida (NO_x) (Z. Ding et al., 2025). Mengingat dampak buruknya terhadap iklim, ambang batas emisi ini diawasi oleh regulasi lingkungan, sehingga operator wajib memantaunya secara presisi dan *real-time* (Lei et al., 2025).

Selama ini, pemantauan emisi mengandalkan perangkat keras *Continuous Emission Monitoring Systems* (CEMS) pada cerobong pembuangan, yang memiliki keterbatasan seperti biaya instalasi yang tinggi serta kebutuhan untuk pemeliharaan dan kalibrasi yang berlanjut (N. Ding et al., 2025; F. Wang et al., 2025). Sebagai solusi yang lebih efisien, industri mulai mengimplementasikan *Predictive Emission Monitoring Systems* (PEMS) berbasis machine learning untuk memprediksi Tingkat emisi CO berdasarkan korelasi data operasional turbin, seperti suhu udara dan tekanan kompressor (Kochueva & Nikolskii, 2021). Oleh karena itu, eksperimen ini menyimulasikan PEMS dengan membandingkan model baseline Regresi Linear Standar dengan Regresi Huber yang didesain tangguh terhadap outlier pada data sensor untuk mengevaluasi algoritma dengan prediksi emisi paling akurat.

1.2 Sumber Dan Deskripsi Dataset

Dataset yang digunakan dalam eksperimen ini adalah Gas Turbine CO and Nox Emission Dataset yang secara spesifik menggunakan subsample pada tahun 2015 yang diperoleh dari [UC Irvine Machine Learning Repository](#). Secara keseluruhan dataset ini memuat rekaman historis agregasi per jam dari sensor sebuah turbin gas yang berlokasi di negara Turki, yang mencatat berbagai parameter operasional mesin serta kondisi lingkungan disekitar. Secara teknis dataset ini memiliki sebanyak 7.384 baris data dan 10 kolom fitur dan 1 target.

No	Nama Fitur	Deskripsi	Satuan	Keterangan
1	AT	Ambient Temperature	°C	Suhu lingkungan
2	AP	Ambient Pressure	mbar	Tekanan lingkungan
3	AH	Ambient Humidity	%	Kelembaban lingkungan
4	AFDP	Air Filter Difference Pressure	mbar	Tekanan diferensial filter udara

5	GTEP	Gas Turbine Exhaust Pressure	mbar	Tekanan buang turbin gas
6	TIT	Turbine Inlet Temperature	°C	Suhu masuk turbin
7	TAT	Turbine After Temperature	°C	Suhu setelah turbin
8	CDP	Compressor Discharge Pressure	mbar	Tekanan keluar kompresor
9	TEY	Turbine Energy Yield	MWh	Energi yang dihasilkan
10	NOX	Nitrogen Oxides	mg/m ³	Emisi nitrogen oksida
Target	CO	Carbon Monoxide	mg/m³	Emisi karbon monoksida

1.3 Pipeline Preprocessing

Proses preprocessing terdiri atas dua tahap utama, yaitu deteksi outlier dan normalisasi fitur. Pertama, outlier dideteksi menggunakan metode Z-Score dengan threshold $|z| > 3$. Teknik ini dipilih karena mampu mengidentifikasi nilai yang menyimpang jauh dari rata-rata berbasis deviasi standar. Hasil analisis menunjukkan bahwa fitur TAT, NOX, CO, dan AP memiliki proporsi outlier paling tinggi. Outlier tidak dihapus karena dianggap merepresentasikan kondisi operasi nyata pada turbin gas, sehingga dibiarkan tetap ada dalam dataset.

Tahap kedua adalah pembangunan preprocessing pipeline menggunakan *scikit-learn*. Pipeline ini berisi langkah standardisasi menggunakan *StandardScaler*, yang bertujuan menormalkan seluruh fitur ke skala yang sama (mean = 0, std = 1). Pipeline kemudian digabungkan dengan skema K-Fold Cross Validation, sehingga pada setiap fold, proses scaling dilakukan hanya pada data training untuk mencegah data leakage. Hasil scaling kemudian diterapkan pada data validation dalam fold tersebut. Dengan pendekatan ini, preprocessing menjadi konsisten, reproducible, dan bebas kebocoran data

```
data_baru = pd.DataFrame([[...]], columns=X.columns)
data_baru_processed = pipeline.transform(data_baru)
```

Pipeline ini memastikan seluruh data diproses secara seragam sehingga model dapat bekerja optimal pada tahap pelatihan maupun inferensi.

BAB II METODOLOGI

2.1 Keterbaruan dan Modifikasi Kode

Implementasi awal model diperoleh dari AI untuk menghasilkan kode regresi linier. Kode mencakup proses pembacaan data, pemisahan variabel fitur dan target, serta penerapan K-Fold Cross Validation untuk evaluasi model. Namun, kode awal belum mencakup perhitungan metrik MAPE dan belum menghasilkan experiment log.

Kemudian kami menambahkan perhitungan metrik Mean Absolute Percentage Error (MAPE) agar evaluasi model sesuai dengan tugas. Selain itu, ditambahkan fitur experiment log dalam bentuk tabel yang mencatat informasi model, metode outlier, jumlah fold, parameter, serta hasil metrik evaluasi. Penambahan lain yang dilakukan adalah penambahan variabel konfigurasi pada bagian awal kode, seperti pengaturan path dataset, jumlah K-Fold, serta nilai threshold Z-Score untuk deteksi outlier agar code lebih fleksibel dan mudah disesuaikan tanpa perlu mengubah keseluruhan kode utama.

2.2 Perancangan Stress Test

Keberadaan outlier dalam dataset emisi turbin gas berpotensi memengaruhi kestabilan model regresi linier, khususnya pada Model Regresi Linear biasa. Oleh karena itu dilakukan perancangan stress test untuk mengevaluasi ketahanan model terhadap kondisi data ekstrem. Stress test dirancang dengan menambahkan outlier sintetis pada target emisi CO guna mensimulasikan gangguan operasional atau fluktuasi ekstrem pada sistem pembakaran turbin gas. Pada tahap awal, deteksi outlier dilakukan menggunakan metode Z-Score dengan threshold > 3 , dan diperoleh sebanyak 161 data yang teridentifikasi sebagai outlier. Selanjutnya, untuk meningkatkan tingkat keparahan distribusi data, ditambahkan 600 data secara acak sebagai outlier tambahan. Seluruh data yang termasuk dalam kategori outlier diperparah dengan mengalikan nilai target CO sebesar lima kali. Dengan pendekatan ini, jumlah data ekstrem meningkat menjadi 752 data atau sekitar 10% dari total dataset, sehingga menciptakan kondisi distribusi yang lebih berat untuk menguji robustness model.

BAB III HASIL DAN PEMBAHASAN

3.1 Experiment Log dan Evaluasi Metrik

Bagian ini menyajikan rangkaian eksperimen yang telah dilakukan untuk mengevaluasi performa model regresi baseline dengan model regresi lanjutan (Huber). Hasil eksperimen dicatat pada tabel-tabel experiment log dan evaluasi metrik berikut

Model	K-Fold	MAE	RMSE	MAPE	R ²	Notes
LinearRegression	5	0.5254	1.1193	0.2294	0.7447	Baseline OLS
HuberRegressor	5	0.5175	1.1202	0.2241	0.7441	Robust to outliers
LinearRegression	5	4.0213	7.8250	1.0018	0.4240	OLS + Outlier Stress
HuberRegressor	5	2.5594	9.4627	0.2924	0.1593	Huber + Outlier Stress

Evaluasi performa model dilakukan menggunakan metode 5-Fold Cross Validation untuk memperoleh estimasi yang lebih stabil. Dataset dibagi menjadi lima bagian dan digunakan secara bergantian sebagai data latih dan data uji sehingga hasil evaluasi lebih representatif.

1. Model Linear Regression (Baseline OLS) pada kondisi Z-Score > 3 , memperoleh MAE sebesar 0.5254 ± 0.0364 , RMSE sebesar 1.1193 ± 0.2888 , MAPE sebesar 0.2294 ± 0.0266 , dan R² sebesar 0.7447 ± 0.0937 . Model mampu menjelaskan sekitar 74% variasi data CO.
2. Model Huber Regressor pada kondisi yang sama memperoleh MAE sebesar 0.5175 ± 0.0377 , RMSE sebesar 1.1202 ± 0.2918 , MAPE sebesar 0.2241 ± 0.0272 , dan R² sebesar 0.7441 ± 0.0947 . Nilai MAE dan MAPE sedikit lebih rendah dibandingkan Linear Regression.
3. Pada kondisi outlier stress test, performa Linear Regression menurun signifikan dengan MAE 4.0213, RMSE 7.8250, MAPE 1.0018, dan R² 0.4240.
4. Pada kondisi yang sama, Huber Regressor memperoleh MAE 2.5594, RMSE 9.4627, MAPE 0.2924, dan R² 0.1593, menunjukkan ketahanan yang lebih baik terhadap outlier ekstrem pada metrik MAE dan MAPE.

Perbandingan hasil menunjukkan bahwa pada kondisi normal (Z-Score > 3), Huber Regressor menghasilkan nilai MAE dan MAPE yang sedikit lebih rendah dibandingkan Linear Regression, sementara nilai RMSE dan R² keduanya relatif serupa. Hal ini menunjukkan bahwa jumlah outlier awal dalam dataset belum memberikan dampak signifikan terhadap performa OLS. Namun, pada kondisi outlier stress (penambahan 600 outlier dan $y \times 5$), performa Linear Regression menurun secara drastis, sedangkan Huber Regressor tetap menunjukkan kesalahan yang lebih terkendali terutama pada metrik MAE dan MAPE. Temuan ini mengindikasikan bahwa Huber lebih robust terhadap outlier ekstrem dibandingkan model OLS.

3.2 Perbandingan baseline regresi linier dengan model regresi Huber

Linear Regression (Ordinary Least Squares/OLS) digunakan sebagai model baseline karena metode ini merupakan regresi linier standar yang umum diterapkan dalam analisis prediksi dan mudah diinterpretasikan. OLS meminimalkan kuadrat selisih antara nilai aktual dan nilai prediksi, sehingga residual yang besar dapat memberikan pengaruh signifikan terhadap estimasi parameter. Hasil deteksi menggunakan metode Z-Score menunjukkan bahwa dataset Gas Turbine 2015 mengandung sejumlah outlier, sehingga performa model baseline berpotensi terpengaruh oleh nilai ekstrem tersebut. Huber Regressor dipilih sebagai model pembanding karena tetap mempertahankan bentuk regresi linier namun dirancang untuk mengurangi sensitivitas terhadap outlier. Literatur menunjukkan bahwa Huber regression memiliki estimasi yang lebih stabil pada data yang mengandung outlier atau error bertipe heavy-tailed, serta mampu mempertahankan akurasi tanpa terlalu dipengaruhi oleh residual besar (Feng & Wu, 2022; Y. Wang et al., 2022).

BAB IV STRESS TEST

4.1 Stress Test terhadap Outlier

Evaluasi pada skenario stress test menunjukkan adanya penurunan performa model yang signifikan dibandingkan kondisi normal. Perubahan distribusi data akibat penerapan stress test berdampak langsung terhadap kestabilan model regresi dalam memprediksi emisi CO. Model Linear Regression mengalami lonjakan nilai MAE dan RMSE yang cukup besar serta penurunan nilai R^2 secara drastis. Peningkatan error ini menunjukkan bahwa model baseline sangat sensitif terhadap nilai ekstrem yang muncul pada data. Residual yang besar memberikan pengaruh dominan terhadap estimasi parameter sehingga kemampuan model dalam menjelaskan variasi data menurun. Pada kondisi yang sama, Huber Regressor juga mengalami penurunan performa, namun nilai MAE dan MAPE tetap lebih rendah dibandingkan Linear Regression. Meskipun RMSE dan R^2 turut mengalami penurunan, tingkat degradasi performa Huber relatif lebih terkendali.

4.2 Analisis Stress Test terhadap Performa Model

Stress test yang dilakukan menyebabkan perubahan distribusi target CO secara signifikan. Penambahan outlier sintesis dan pengalihan nilai target menghasilkan distribusi dengan variansi lebih besar dan ekor distribusi yang lebih berat (heavy-tailed distribution). Perubahan karakteristik ini termasuk dalam kategori distribution shift, karena distribusi data setelah stress tidak lagi menyerupai distribusi awal. Dalam kondisi ini, model yang menggunakan pendekatan squared loss seperti OLS menjadi sangat sensitif terhadap residual besar. Karena error dikuadratkan, nilai ekstrem memiliki pengaruh dominan terhadap estimasi parameter, sehingga menghasilkan lonjakan RMSE dan penurunan R^2 yang signifikan.

Sebaliknya, Huber Regressor menggunakan fungsi loss yang membatasi penalti pada residual besar. Pada error kecil, model berperilaku seperti regresi linier biasa, namun pada error besar penalti bersifat linear sehingga pengaruh outlier tidak terlalu mendominasi proses pembelajaran. Hal ini menjelaskan mengapa MAE dan MAPE pada Huber lebih terkendali dibandingkan OLS dalam kondisi stress.

BAB V

KESIMPULAN

Berdasarkan hasil eksperimen pada dataset Gas Turbine CO and NOx Emission Data 2015, model regresi dapat digunakan untuk memprediksi emisi karbon monoksida (CO) pada turbin gas sebagai bagian dari simulasi Predictive Emission Monitoring Systems (PEMS). Proses preprocessing dilakukan melalui deteksi outlier menggunakan metode Z-Score serta normalisasi fitur menggunakan StandardScaler dalam pipeline preprocessing.

Hasil evaluasi menunjukkan bahwa pada kondisi data normal, Linear Regression dan Huber Regressor memiliki performa yang relatif serupa. Namun pada kondisi stress test dengan penambahan outlier, performa Linear Regression menurun secara signifikan, sedangkan Huber Regressor lebih stabil terhadap data ekstrem. Dengan demikian, Huber Regression lebih robust terhadap outlier dibandingkan regresi linear standar, sehingga lebih sesuai digunakan untuk prediksi emisi pada data sensor industri yang berpotensi mengandung nilai ekstrem.

TAUTAN

Tautan Github: https://github.com/AppleCraft2005/ML_Assignment_regression

Tautan Youtube: <https://youtu.be/pBcB7GQWvmU?si=0hQKg36Dkg8zpgY->

DAFTAR PUSTAKA

- Ding, N., Xi, Y., Jiang, W., Li, H., Su, J., Yang, S., & Lie, T. T. (2025). State-of-the-art carbon metering: Continuous emission monitoring systems for industrial applications. In *Heliyon* (Vol. 11, Number 3). Elsevier Ltd. <https://doi.org/10.1016/j.heliyon.2025.e42308>
- Ding, Z., Song, X., & Zhang, Y. (2025). Research on CO and NOx emission prediction of gas turbines based on CPO-LSSVM algorithm. *Proceedings of 2025 2nd International Conference on Image Processing, Intelligent Control and Computer Engineering, IPICE 2025*, 31–35. <https://doi.org/10.1145/3768184.3768191>
- Feng, Y., & Wu, Q. (2022). A statistical learning assessment of Huber regression. *Journal of Approximation Theory*, 273. <https://doi.org/10.1016/j.jat.2021.105660>
- Global electricity demand is set to grow strongly to 2030, underscoring need for investments in grids and flexibility - News - IEA*. (n.d.). Retrieved February 25, 2026, from https://www.iea.org/news/global-electricity-demand-is-set-to-grow-strongly-to-2030-underscoring-need-for-investments-in-grids-and-flexibility?utm_source=chatgpt.com
- Kochueva, O., & Nikolskii, K. (2021). Data analysis and symbolic regression models for predicting co and nox emissions from gas turbines. *Computation*, 9(12). <https://doi.org/10.3390/computation9120139>
- Lei, J., Chen, F., Liu, L., Liu, Z., & Xiong, X. (2025). Comparison and Optimization Path of Quality Control Systems for Direct Carbon Emission Measurement Data in Thermal Power Plants. In *Energies* (Vol. 18, Number 20). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/en18205482>
- Wang, F., Pang, Y., Bai, L., & Godin, M. (2025). Researching the landscape of predictive emissions monitoring system: a review of literature and technology trends. In *Environmental Systems Research* (Vol. 14, Number 1). Springer Medizin. <https://doi.org/10.1186/s40068-025-00403-9>
- Wang, Y., Wang, B., Peng, C., Li, X., & Yin, H. (2022). Huber Regression Analysis with a Semi-Supervised Method. *Mathematics*, 10(20). <https://doi.org/10.3390/math10203734>